

# 추정

CE730 통계와 금융

조남운

# 목차

- 표본분포
- 추정
  - 추정에 대한 기본 개념
  - 추정방법

표본분포

# 표본분포 Sampling Distribution

- 표본으로 만들어진 통계량의 분포

- 표본평균의 분포

$$\bar{X} := \sum_{i=1}^n X_i/n$$

- 표본분산의 분포

$$s^2 := \sum_{i=1}^n (X_i - \bar{X})^2/(n-1)$$

- 표본공분산의 분포

$$\text{Cov}(X, Y) := \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})/n$$

- 등등

- CLT는 이 중 표본평균의 분포에 대한 이론


# 표본도 확률분포를 가질 수 있다

- 동전 두 개 던져서 앞면 갯수 맞추기
  - 이 사건의 확률분포는
    - $0 \rightarrow 1/4, 1 \rightarrow 1/2, 2 \rightarrow 1/4$
- 표본은 관측 전후에 따라 의미가 달라짐
  - 표본(표집전): 확률분포를 가지는 확률변수
  - 표본(표집후): 정해진 값을 가진 관측치 (확률변수가 아님)

# 표본분포의 가계도

그림 5.20: 표본분포의 가계도

도출  
↓




수렴  
↑

# 카이제곱분포

- 표준정규분포를 따르는 확률변수의 제곱합의 분포
- 모수:  $k$ 
  - df (degree of freedom)
  - 자유도

$$Z_i \sim iidN(0,1^2), \quad i = 1, 2, \dots, k$$

$$Q = \sum_i^k Z_i^2 \sim \chi^2(k)$$



# 카이제곱분포: 주요성질


$$Z \sim N(0,1)$$

$$X \sim \chi^2(n_1)$$

$$Y \sim \chi^2(n_2)$$

$$\text{Cov}(Z, X) = 0$$

$$\text{Cov}(X, Y) = 0$$



$$\text{C1} \quad Z^2 \sim \chi^2(1)$$

$$\text{C2} \quad X + Y \sim \chi^2(n_1 + n_2)$$

$$\text{C3} \quad \frac{Z}{\sqrt{X/n_1}} \sim t(n_1)$$

$$\text{C4} \quad \frac{X/n_1}{Y/n_2} \sim F(n_1, n_2)$$



# 표본분포

$$C1 \quad Z^2 \sim \chi^2(1)$$

$$C2 \quad X + Y \sim \chi^2(n_1 + n_2)$$

$$C3 \quad \frac{Z}{\sqrt{X/n_1}} \sim t(n_1)$$

$$C4 \quad \frac{X/n_1}{Y/n_2} \sim F(n_1, n_2)$$

$$X_i \sim iidN(\mu_x, \sigma_x^2), \quad i = 1, 2, \dots, n$$

$$(1) \quad \sum_i^n \left( \frac{X_i - \mu_x}{\sigma_x} \right)^2 \sim \chi^2(n)$$

$$(2) \quad \sum_i^n \left( \frac{X_i - \bar{X}}{\sigma_x} \right)^2 = \frac{(n-1)s_x^2}{\sigma_x^2} \sim \chi^2(n-1)$$

$$C1 \quad Z^2 \sim \chi^2(1)$$

$$C2 \quad X + Y \sim \chi^2(n_1 + n_2)$$

$$C3 \quad \frac{Z}{\sqrt{X/n_1}} \sim t(n_1)$$

$$C4 \quad \frac{X/n_1}{Y/n_2} \sim F(n_1, n_2)$$

$$\bar{X} \sim N(\mu_x, \sigma_x^2/n)$$

$$\frac{\bar{X} - \mu_x}{\sqrt{\sigma_x^2/n}} \sim N(0,1)$$

$$(3) \quad \frac{\frac{\bar{X} - \mu_x}{\sqrt{\sigma_x^2/n}}}{\sqrt{\frac{(n-1)s_x^2}{\sigma_x^2}/(n-1)}} = \frac{\sqrt{n}(\bar{X} - \mu)}{s_x} \sim t(n-1)$$

(4)

$$X_i \sim iidN(\mu_x, \sigma_x^2), \quad i = 1, 2, \dots, n$$

$$Y_i \sim iidN(\mu_y, \sigma_y^2), \quad i = 1, 2, \dots, m$$

C1  $Z^2 \sim \chi^2(1)$

C2  $X + Y \sim \chi^2(n_1 + n_2)$

C3  $\frac{Z}{\sqrt{X/n_1}} \sim t(n_1)$

C4  $\frac{X/n_1}{Y/n_2} \sim F(n_1, n_2)$

$$s_y^2 := \sum_i^m (Y_i - \bar{Y})^2 / (m - 1)$$

$$\frac{(m - 1)s_y^2}{\sigma_y^2} \sim \chi^2(m - 1)$$

$$(4) \quad \frac{s_x^2 / \sigma_x^2}{s_y^2 / \sigma_y^2} \sim F(n - 1, m - 1)$$

# 자유도

## Degree of Freedom

- 값이 변동 가능한 표본의 갯수
- 통상적으로 표본이  $n$ 개라면 자유도도  $n$ 임
  - $n$ 개의 표본이 동시에 달라져도 상관 없기 때문
- 하지만 표본분산의 자유도는  $n-1$ 임
  - 모평균 대신 표본평균을 사용  $\Rightarrow$  표본평균값이 존재하기 때문에  $n$ 개의 표본 중 1개 표본값은  $n-1$ 개의 표본값이 정해지면 자동 결정됨  $\Rightarrow df=n-1$

# 일반화된 자유도의 규칙

- 어떤 통계량 계산을 위해  $n$ 개의 표본을 사용
- 통계량 계산을 위해 표본으로부터 미리 추정한 모수의 추정량이  $k$ 개인 경우
- $df = n - k$

# 모집단 분포가 정규분포 가 아닐 경우의 표본분포

$$Y \sim B(n, p)$$

$$Y/n \sim ?$$

$$\frac{Y/n - E(Y/n)}{\sqrt{\text{Var}(Y/n)}} = \frac{Y/n - p}{\sqrt{p(1-p)/n}} \xrightarrow{d} N(0,1)$$

$$Y/n \sim N(p, p(1-p)/n)$$

- CLT를 이용하여 근사적으로 표본분포 도출
- $n$ 이 정규분포에 근사할 정도로 충분히 커야 함
- 모집단 분포를 모르고  $n$ 도 충분히 크지 않다면 비모수적 방법을 사용해야 함
  - Jackknifing, Bootstrapping 등

# 과제|2: CLT 검증

- $U(0,100)$ 을 따르는 데이터 10000개 생성: 모집단으로 간주
- 이 모집단에서 1, 10, 100 의 크기로 이루어진 표본을 반복 표집
  - 각 표본평균 1개 10개, 50개, 500개, 5000개의 분포를 히스토그램으로 그리기
  - CLT가 맞다면 표본평균의 분포는 정규분포에 수렴할 것임
  - Bonus: 표본분산 10, 50, 500, 5000개의 분포도 그려보자
- rmarkdown으로 작성하여 제출할 것
  - 템플릿 파일은 lms에 게시. 이 템플릿 파일의 내용을 채워 제출할 것
  - R markdown은 이 링크에서 다운로드
    - <https://rmarkdown.rstudio.com>
- 기한: 11/30 (금) 15:00


# 추정 Estimation



# 정확도, 정밀도, 분산

## Accuracy, Precision, Variance

- 정확도(Accuracy): 참값과 추정값(착탄점의 평균)의 차이
- 정밀도(Precision): 착탄점의 분포된 정도
  - Variance를 여기에 쓰는 경우도 있음
- 좋은 추정량: 정확도와 정밀도가 높은 추정량
- 지표: MSE (Mean Squared Error)



# MSE: Definition

## Mean Squared Error

- $\hat{\theta}$ : 모수  $\theta$ 에 대한 추정량 (확률변수)
- 모수  $\theta$ : 상수
- $E(\hat{\theta})$ : 상수
- 좋은 추정량의 가장 중요한 성질은 Bias가 없는 것
  - 불편성 (unbiasedness)
  - 일치성 (consistency)
  - 효율성 (efficiency)
  - 충분성 (sufficiency)

$$\begin{aligned}MSE(\hat{\theta}) &:= E(\hat{\theta} - \theta)^2 \\&= E(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2 \\&= E(\hat{\theta} - E(\hat{\theta}))^2 + (E(\hat{\theta}) - \theta)^2 \\&= Var(\hat{\theta}) + Bias^2\end{aligned}$$

$$Bias := E(\hat{\theta}) - \theta$$

$$[E(E(X)) = E(X)]$$

# 불편성 Unbiasedness

- $\hat{\theta}$ : 추정량
- $\theta$ : 모수
- Bias=0 인 추정량은 불편성을 만족함
  - 정확도를 보장함을 의미
- 불편성을 보장하는 분산이 가장 작은 추정량: UMVUE (Uniformly Minimum Variance Unbiased Estimator)

$$E(\hat{\theta}) = \theta \Rightarrow Bias = 0$$

# 불편추정량의 예

- 모평균이  $\mu$ 인 모집단에서 추출된 임의표본의 평균인  $\bar{X}$ 는  $\mu$ 의 불편추정량
- $X_i$ 가 성공확률  $p$ 인 베르누이 시행이라면  $\hat{p}$ 는  $p$ 에 대한 불편추정량

$$E(\bar{X}) = \frac{1}{n} E \left( \sum_i^n X_i \right) = n\mu/n = \mu$$

# 일치성 Consistency

- $\hat{\theta}_n$ 가  $n$ 표본으로부터 계산된 경우
- $n$ 이 증가함에 따라  $\hat{\theta}_n$ 가 모수  $\theta$ 에 수렴할 경우  $\hat{\theta}_n$ 는  $\theta$ 에 대한 일치추정량이라고 정의
- $\hat{\theta}_n$ 의 MSE가 0에 수렴하면  $\hat{\theta}_n$ 는  $\theta$ 의 일치추정량

$\hat{\theta}_n$  is consistent estimator of  $\theta$  if:

$$\text{plim}_{n \rightarrow \infty} E(\hat{\theta}_n - \theta) = 0$$

$$\forall \epsilon > 0, \quad P(|\hat{\theta}_n - \theta| > \epsilon) \rightarrow 0$$

# 표준오차 Standard Error

$$Var(\hat{\theta}_n) := E(\hat{\theta}_n - E(\hat{\theta}_n))^2$$

$$SE := \sqrt{Var(\hat{\theta}_n)}$$

- 표준오차의 정의
  - 추정량의 표준편차

# 불편추정량이지만 일치성을 만족하지 못하는 경우

	불편성	일치성
hat theta1	만족	불만족
hat theta2	만족	만족

$$X_i \sim iid?(\mu, \sigma^2)$$

$$\hat{\theta}_1 := (X_1 + X_n)/2$$

$$\hat{\theta}_2 := \bar{X} = \sum_i^n X_i/n$$

(mu에 대한 추정량임)

$$MSE(\hat{\theta}_1) \rightarrow \sigma^2/2$$

# 불편성은 만족하지 않지만 일치추정량인 경우

$$X_i \sim iid?(\mu, \sigma^2)$$

$$\hat{\theta}_3 := \sum_i^n X_i / (n + 1)$$

$$E(\hat{\theta}_3) = n\mu / (n + 1) \neq \mu$$

Biased!

$$Var(\hat{\theta}_3) = (\sigma^2/n)[n^2/(n+1)^2] = n\sigma^2/(n+1)^2$$

$$\begin{aligned} MSE(\hat{\theta}_3) &= Var(\hat{\theta}_3) + (E(\hat{\theta}_3) - \mu)^2 \\ &= \frac{n}{(n+1)^2} \sigma^2 + \left( \frac{-\mu}{n+1} \right)^2 \rightarrow 0 \quad \text{as } n \rightarrow \infty \end{aligned}$$

Consistent!



# 효율성 Efficiency

- 모수를 추정하기 위해 동일한 크기의 표본을 이용한 추정량들 중 가장 작은 MSE를 가진 추정량
- 효율적 추정량은 MVUE임
  - Minimum Variance Unbiased Estimator

$$\hat{\theta}_1 := \frac{X_1 + X_2 + \cdots + X_{n-1} + 2X_n}{n+1},$$

$$\hat{\theta}_2 := \bar{X}$$

$$E(\hat{\theta}_1) = E(\hat{\theta}_2) = \mu$$

Unbiased!

$$MSE(\hat{\theta}_1) = \frac{\sigma^2(n-1+4)}{(n+1)^2}$$

Consistent!

$$MSE(\hat{\theta}_2) = \sigma^2/n$$

Consistent!

$$MSE(\hat{\theta}_1) - MSE(\hat{\theta}_2) = \sigma^2 \frac{n-1}{n(n-1)^2} > 0$$

theta2 is more efficient

# 충분성 Sufficiency

$f(x_1, \dots, x_n; \theta)$       결합분포함수

$X_1, \dots, X_n$

$f$ 의 분포로부터 구한 표본

$\theta$       모수

$f(X_1, \dots, X_n | T = t)$

통계량  $T = t$ 로 주어졌을 때  
표본의 조건부 분포함수

- $T$ 가  $\theta$ 의 충분통계량일 조건
  - $T=t$ 로 주어져 있을 때 표본의 조건부 분포함수가 모수  $\theta$ 에 의존하지 않을 것
- $T$ 가 모수  $\theta$ 에 대한 정보를 모두 가지고 있다는 의미

# 좋은 통계량의 조건 Good Estimator

- 불편성 Unbiasedness
- 일치성 Consistency
- 효율성 Efficiency
- 충분성 Sufficiency

# 추정 방법

# 추정 방법의 종류

- 점 추정법 Point Estimation
  - 적률 추정 Moment Estimation
  - 최우추정 Maximum Likelihood Estimation
  - 최소제곱추정 Least Squared Estimation
- 구간 추정법 Interval Estimation

# 적률추정 Moment Estimation

- k차 적률
  - kth order moment
  - 평균은 1차적률
  - 분산은 2차적률
  - 왜도는 3차적률
  - 첨도는 4차적률
- 모수인 k차 적률에 대한 추정량인 k차 표본적률은 대체로 좋은 추정량임

$$k\text{차 적률} := E(X^k) \quad (\text{모수})$$

$$k\text{차 표본적률} := \frac{1}{n} \sum_i^n X_i^k \quad (\text{추정량})$$

# 최우추정량

## MLE: Maximum Likelihood Estimation

- 우도함수(Likelihood function)를 극대화하는 추정량
- 관측된 표본값을 모수로 가지는  $\theta$ (vector)의 함수
- 여전히 결합분포함수이므로 이 함수값이 높다는 것은 발생 확률이 높다는 것을 의미함
- MLE의 아이디어: 우도함수를 극대화하는 모수를 찾는 방식으로 추정량 결정
  - $X_i = x_i$  로 관측될 가능성을 가장 크게 만드는 모수  $\theta$  를 찾는 것

$X_1, X_2, \dots, X_n$  표본(관측전: 확률변수)

$f(x_1, \dots, x_n; \theta)$  표본의 결합분포함수

$x_1, x_2, \dots, x_n$  표본값(관측후: 일반변수)

$L(\theta; x_1, \dots, x_n)$  우도함수

$\arg \max_{\theta} L(\theta; x_1, \dots, x_n)$  MLE

# $f(x, y; a, b, c)$ and $g(a, b, c; x, y)$ : Exercise

$$f(x, y; a, b, c) := ax + bxy + cy + 1$$

$x, y$ 의 함수.  $a, b, c$ 는 모수(parameter)

$$g(a, b, c; x, y) := ax + bxy + cy + 1$$

$a, b, c$ 의 함수.  $x, y$ 는 모수(parameter)



# 다변수 함수의 극대화

# 다변수 함수의 미분

- MLE: 극대화문제의 일종
- 우도함수는 다변수함수이므로 MLE는 다변수함수의 극대화문제를 풀 수 있어야 함
- 다변수함수: input, 또는 output이 벡터인 함수
  - MLE에서는 input이 다변수인 경우만 다룸
  - Maximum을 찾는 문제는 다변수의 경우 불가능

# 전체구조

- 편미분
- 전미분
- 극대화문제의 1계조건
- 극대화문제의 2계조건

# Partial Derivative

Let  $f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$  and  $\mathbf{e}_i$  be a vector whose  $i$ th element is 1 and others are 0.

$$\mathbf{e}_i := (\overbrace{0, 0, \dots, 0}^i, 1, 0, \dots, 0)$$

## Definition (Partial Derivative)

Partial derivative at  $\bar{\mathbf{x}}_0 \in D$  is

$$\frac{\partial f}{\partial x_i} := \lim_{h \rightarrow 0} \frac{f(\bar{\mathbf{x}}_0 + h\mathbf{e}_i) - f(\bar{\mathbf{x}}_0)}{h}$$

When  $n = 1$ , partial derivative is equivalent to derivative of one variable function.

## Calculation Procedure

- Treat  $x_i$  as the only variable in  $f$
- Treat  $x_{-i}$  as constant

# Partial Derivative: Geometric Interpretation

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}$$

- Think of  $f(\mathbf{x}) = x_1^2 + x_2^2$ .
- If  $x_2 = \bar{x}_2$ ,  $f(x_1, \bar{x}_2)$  is equivalent to one variable function  $\tilde{f}(x_1) = x_1^2 + \bar{x}_2^2$ .
- Graph of  $\tilde{f}$  is intersection of the graph of  $f$  with the slice  $x_2 = \bar{x}_2$ .
- $\frac{\partial f}{\partial x_1}(\bar{x}_1, \bar{x}_2) = \frac{\partial \tilde{f}}{\partial x_1}(\bar{x}_1)$  is the slope of  $\tilde{f}$  on  $\bar{x}_1$ , slope of the tangent line to the curve  $\tilde{f}$  (on the plane  $x_2 = \bar{x}_2$ )

# Example





Figure: Graph of  $z = x^2 + xy + y^2$  with intersection  $y = 1$

# Geometrical Approach

## Finding Tangent Plane

Let  $f : \mathbb{R}^2 \rightarrow \mathbb{R}$  is differentiable. When finding a tangent plane on  $(\bar{x}_1, \bar{x}_2)$ , we need to get at least two independent vectors:

$\left(1, 0, \frac{\partial f}{\partial x_1}(\bar{x}_1, \bar{x}_2)\right)$  (slice  $x_2 = \bar{x}_2$ ), and  $\left(0, 1, \frac{\partial f}{\partial x_2}(\bar{x}_1, \bar{x}_2)\right)$  (slice  $x_1 = \bar{x}_1$ )

Then the tangent plane with two parameters  $\Delta x_1, \Delta x_2$  is:

$$\begin{aligned} & (\bar{x}_1, \bar{x}_2, f(\bar{\mathbf{x}})) + \Delta x_1 \left(1, 0, \frac{\partial f}{\partial x_1}(\bar{x}_1, \bar{x}_2)\right) + \Delta x_2 \left(0, 1, \frac{\partial f}{\partial x_2}(\bar{x}_1, \bar{x}_2)\right) \\ &= \left(\bar{x}_1 + \Delta x_1, \bar{x}_2 + \Delta x_2, f(\bar{\mathbf{x}}) + \frac{\partial f}{\partial x_1}(\bar{x}_1, \bar{x}_2)\Delta x_1 + \frac{\partial f}{\partial x_2}(\bar{x}_1, \bar{x}_2)\Delta x_2\right) \end{aligned}$$

This interpretation can be extended to  $n$  dimension.

# The Total Derivative

Changes in All Direction:  $f : \mathbb{R}^n \rightarrow \mathbb{R}^1$

Let  $d\mathbf{x} = (dx_1, \dots, dx_n)$  and  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ , differentiable. Then small change of  $d\mathbf{x}$  will cause small change of  $df = f(\bar{\mathbf{x}} + d\bar{\mathbf{x}}) - f(\bar{\mathbf{x}}) \in \mathbb{R}$  and

$$df = f(\bar{\mathbf{x}} + d\bar{\mathbf{x}}) - f(\bar{\mathbf{x}}) = \frac{\partial f}{\partial x_1}(\bar{\mathbf{x}})dx_1 + \dots + \frac{\partial f}{\partial x_n}(\bar{\mathbf{x}})dx_n = Df_{\mathbf{x}}d\mathbf{x}$$

And  $Df_{\mathbf{x}} := \left( \frac{\partial f}{\partial x_1}(\bar{\mathbf{x}}) \quad \frac{\partial f}{\partial x_2}(\bar{\mathbf{x}}) \quad \dots \quad \frac{\partial f}{\partial x_n}(\bar{\mathbf{x}}) \right)$ : (Jacobian) derivative of  $f$  at  $\bar{\mathbf{x}}$  or The linear approximation of  $f$  at  $\bar{\mathbf{x}}$ , or Gradient vector  $\nabla f$

Note: In this case,  $Df_{\mathbf{x}}$  is a vector or  $1 \times n$  matrix.



# 다변수 함수의 미분: 결론

$$Df_{\mathbf{x}} := \left( \frac{\partial f}{\partial x_1}(\bar{\mathbf{x}}) \quad \frac{\partial f}{\partial x_2}(\bar{\mathbf{x}}) \quad \cdots \quad \frac{\partial f}{\partial x_n}(\bar{\mathbf{x}}) \right)$$

2계미분은  $n \times n$  행렬이 됨

# Hessian

## Definition

*Hessian matrix*

$$D^2 f_{\mathbf{x}} = D(Df)_{\mathbf{x}} := \begin{pmatrix} \frac{\partial^2 f}{\partial x_1 \partial x_1} & \frac{\partial^2 f}{\partial x_2 \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_1} \\ \frac{\partial^2 f}{\partial x_1 \partial x_2} & \frac{\partial^2 f}{\partial x_2 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_1 \partial x_n} & \frac{\partial^2 f}{\partial x_2 \partial x_n} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_n} \end{pmatrix}$$

## Theorem (14.5: Young's theorem)

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i} \quad \forall i, j$$

This means hessian is symmetric.

# 다변수함수의 극대화문제: 극대화문제의 정의

# Definitions

## Definition ((strict) max/min, (strict) local max/min)

Let  $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}$

- ① A point  $\mathbf{x}^*$  is a (global, or absolute) max, maximizer, maximum point of  $f$  on  $U$  if  $f(\mathbf{x}^*) \geq f(\mathbf{x}) \quad \forall \mathbf{x} \in U$
- ②  $\mathbf{x}^* \in U$  is a strict (global, or absolute) max if  $\mathbf{x}^*$  is a max and  $f(\mathbf{x}^*) > f(\mathbf{x}) \quad \forall \mathbf{x} \in U - \{\mathbf{x}^*\}$
- ③  $\mathbf{x}^* \in U$  is a local (relative) max of  $f$  if  $\exists \epsilon > 0$  s.t.  
 $f(\mathbf{x}^*) \geq f(\mathbf{x}) \quad \forall \mathbf{x} \in B_\epsilon(\mathbf{x}^*) \cap U$
- ④  $\mathbf{x}^* \in U$  is a strict local (relative) max of  $f$  if  $\exists \epsilon > 0$  s.t.  
 $f(\mathbf{x}^*) > f(\mathbf{x}) \quad \forall \mathbf{x} \in B_\epsilon(\mathbf{x}^*) \cap U - \{\mathbf{x}^*\}$

- Definition of min:  $>, \geq \rightarrow <, \leq$

## Theorem (17.1)

*Let  $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}$  be a  $C^1$  function. If  $\mathbf{x}^*$  is a local max or min of  $f$  and  $\mathbf{x}^*$  is an interior point of  $U$ , then*

$$\frac{\partial f}{\partial x_i}(\mathbf{x}^*) = 0 \quad \forall i$$

*In short,*

$$Df_{\mathbf{x}}(\mathbf{x}^*) = \mathbf{0}$$

*$\mathbf{x}^*$  is a critical point of  $f$*

Note: Compare with one-var version FOC (Theorem 3.3)

## Theorem (3.3: First Order Condition (FOC))

*$x_0$  is an interior max or min of  $f \Rightarrow x_0$  is a critical point of  $f$ . i.e.,  $f'(x_0) = 0$  (Inverse is not always true)*

# SOC (Sufficient Conditions)

## Theorem (17.2)

Let  $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}$  be a  $C^2$  function and  $U$  is open. Suppose  $\mathbf{x}^*$  is a critical point of  $f$ . (i.e.,  $Df_{\mathbf{x}}(\mathbf{x}^*) = \mathbf{0}$ ) Then,

- ① If Hessian ( $D^2 f_{\mathbf{x}}(\mathbf{x}^*)$ ) is ND, then  $\mathbf{x}^*$  is a strict local max of  $f$
- ② If Hessian ( $D^2 f_{\mathbf{x}}(\mathbf{x}^*)$ ) is PD, then  $\mathbf{x}^*$  is a strict local min of  $f$
- ③ If Hessian is ID,  $\mathbf{x}^*$  is neither a local max nor local min of  $f$ . (saddle point)

Note: one-var version: (Theorem 3.4)

$$f'(x^*) = 0 \quad \wedge \quad f'' < 0 \quad \Rightarrow \quad x^* \text{ is a local max}$$

# Definiteness

## Definiteness: Overview

When  $Q = \mathbf{x}^T A \mathbf{x}$  and  $A$  is a diagonal matrix

$$A = \begin{pmatrix} a_{11} & 0 & 0 & \cdots & 0 \\ 0 & a_{22} & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & a_{nn} \end{pmatrix}$$

- Positive Definite (PD):  $a_{ii} > 0 \quad \forall i$
- Positive Semi Definite (PSD):  $a_{ii} \geq 0 \quad \forall i$
- Negative Definite (ND):  $a_{ii} < 0 \quad \forall i$
- Negative Semi Definite (NSD):  $a_{ii} \leq 0 \quad \forall i$
- Indefinite (ID):  $a_{ii} < 0$  for some  $i$ , and  $a_{ii} > 0$  for some  $i$

# SOC (Necessary Conditions)

## Theorem (17.6)

Let  $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}$  be a  $C^2$  function and  $U$  is open. Then,

- ①  $\mathbf{x}^*$  is a local min of  $f \Rightarrow Df(\mathbf{x}^*) = \mathbf{0} \quad \wedge \quad D^2f(\mathbf{x}^*)$  is PSD
- ②  $\mathbf{x}^*$  is a local max of  $f \Rightarrow Df(\mathbf{x}^*) = \mathbf{0} \quad \wedge \quad D^2f(\mathbf{x}^*)$  is NSD

Note: one-var version:

$$x^* \text{ is local max} \quad \Rightarrow \quad x' = 0 \quad \wedge \quad f'' \leq 0$$



# Finding Global Max/Min

Different from one-var function, condition 1 (below) is not true when  $f$  is multi-var function

## Sufficient Conditions for Global Max/Min ( $f : I \in \mathbb{R} \rightarrow \mathbb{R}$ )

- ①  $x^*$  is a local max/min and  $x^*$  is the only critical point of  $f$  in  $I$
- ②  $f'' \leq 0 \quad \forall I$ . i.e.,  $f$  is concave on  $I$  (max)
  - $f'' \leq 0 \quad \forall I$  (max)
  - $f'' \geq 0 \quad \forall I$  (min)

However, condition 2 is true even when  $f$  is multi-var function!

## Theorem (17.8)

Let  $f : U \in \mathbb{R}^n \rightarrow \mathbb{R}$  be a  $C^2$  function with convex open domain  $U$ .

- ①  $DF(\mathbf{x}^*) = \mathbf{0}$  and  $D^2 f_{\mathbf{x}}$  is PSD on  $U \Rightarrow \mathbf{x}^*$  is a global min of  $f$  on  $U$
- ②  $DF(\mathbf{x}^*) = \mathbf{0}$  and  $D^2 f_{\mathbf{x}}$  is NSD on  $U \Rightarrow \mathbf{x}^*$  is a global max of  $f$  on  $U$

# 로그 우도 함수

## Log Likelihood Function

- 우도함수가 지수형일 때에는 로그를 취할 경우 극대화문제를 풀기 수월해질 수 있음
- 이러한 경우 로그우도함수를 사용
- 로그함수는 단조증가함수이므로 로그우도함수의 극대화 문제의 해는 우도함수의 극대화 문제의 해와 같음

$$\arg \max_{\theta} L(\theta; x_1, \dots, x_n)$$

$$\Leftrightarrow \arg \max_{\theta} \ln L(\theta; x_1, \dots, x_n)$$

# MLE 연습

- 분포의 형태 (분포함수)는 알고 있지만 모수 (모평균, 모분산)는 모르는 상황
- 모수를 추정해야 함
  - 본 연습에서는 MLE의 방법으로 추정 시도

$$X_1, \dots, X_n \sim iid N(\mu, \sigma^2)$$

$$(X_1, \dots, X_n) = (x_1, \dots, x_n)$$

$$\Rightarrow \begin{aligned} \hat{\mu} &= ? \\ \hat{\sigma}^2 &= ? \end{aligned}$$

# 우도함수 유도하기

$$f(x_i; \mu, \sigma^2) = (2\pi\sigma^2)^{-1/2} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

$$f(x_1, \dots, x_n; \mu, \sigma^2) = \prod_i^n f(x_i; \mu, \sigma^2) \quad \text{(by iid assumption)}$$

$$= (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum_i^n (x_i - \mu)^2}{2\sigma^2}\right)$$

$$L(\mu, \sigma^2; x_1, \dots, x_n) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum_i^n (x_i - \mu)^2}{2\sigma^2}\right)$$

(Likelihood Function)

# 로그 우도함수 계산하기

$$L(\mu, \sigma^2; x_1, \dots, x_n) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum_i^n (x_i - \mu)^2}{2\sigma^2}\right)$$

(Likelihood Function)

$$\ln L(\mu, \sigma^2; x_1, \dots, x_n) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_i^n (x_i - \mu)^2$$

(Log-Likelihood Function)

# MLE

$$\arg \max_{\mu, \sigma^2} \ln L$$

로그우도함수의 극대화문제

$$D_{\mu, \sigma^2} \ln L = \begin{pmatrix} \frac{\partial \ln L}{\partial \mu} & \frac{\partial \ln L}{\partial \sigma^2} \end{pmatrix} = (0 \quad 0)$$

FOC

$$D_{\mu, \sigma^2}^2 \ln L = \begin{pmatrix} \frac{\partial^2 \ln L}{\partial^2 \mu} & \frac{\partial^2 \ln L}{\partial \mu \partial \sigma^2} \\ \frac{\partial^2 \ln L}{\partial \sigma^2 \partial \mu} & \frac{\partial^2 \ln L}{\partial^2 \sigma^2} \end{pmatrix} \text{ is ND or NSD}$$

SOC

# FOC

$$D_{\mu, \sigma^2} \ln L = \begin{pmatrix} \frac{\partial \ln L}{\partial \mu} & \frac{\partial \ln L}{\partial \sigma^2} \end{pmatrix} = \begin{pmatrix} 0 & 0 \end{pmatrix}$$

$$\ln L(\mu, \sigma^2; x_1, \dots, x_n) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_i^n (x_i - \mu)^2$$

(Log-Likelihood Function)

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \sum_i^n (x_i - \mu) = 0 \quad \Rightarrow \quad \hat{\mu} = \frac{1}{n} \sum_i^n x_i$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_i^n (x_i - \mu)^2 = 0 \quad \Rightarrow \quad \hat{\sigma}^2 = \frac{1}{n} \sum_i^n (x_i - \hat{\mu})^2$$

# SOC: Passed

$$D_{\mu, \sigma^2}^2 \ln L = \begin{pmatrix} \frac{\partial^2 \ln L}{\partial^2 \mu} & \frac{\partial^2 \ln L}{\partial \mu \partial \sigma^2} \\ \frac{\partial^2 \ln L}{\partial \sigma^2 \partial \mu} & \frac{\partial^2 \ln L}{\partial^2 \sigma^2} \end{pmatrix} \text{ is ND or NSD} \quad \text{SOC}$$

$$\hat{\mu} = \frac{1}{n} \sum_i^n x_i$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_i^n (x_i - \hat{\mu})^2$$

ND

$$D_{\mu, \sigma^2}^2 \ln L(\hat{\mu}, \hat{\sigma}^2) = \begin{pmatrix} -\frac{n\hat{\mu}}{\hat{\sigma}^2} & -\frac{1}{\hat{\sigma}^4} \sum_i^n (x_i - \hat{\mu}) \\ -\frac{1}{\hat{\sigma}^4} \sum_i^n (x_i - \hat{\mu}) & \frac{n}{2\hat{\sigma}^4} - \frac{1}{(\hat{\sigma}^2)^3} \left( \sum_i^n (x_i - \hat{\mu})^2 \right) \end{pmatrix}$$

$$-\frac{1}{\hat{\sigma}^4} \sum_i^n (x_i - \hat{\mu}) = 0 \quad \frac{n}{2\hat{\sigma}^4} - \frac{1}{(\hat{\sigma}^2)^3} \left( \sum_i^n (x_i - \hat{\mu})^2 \right) = \frac{n}{2\hat{\sigma}^4} - \frac{n\hat{\sigma}^2}{(\hat{\sigma}^2)^3} = -\frac{n}{2\hat{\sigma}^4} < 0$$



# 구간추정 Interval Estimation

# 신뢰구간

## CI: Confidence Interval

- $d\%$  신뢰구간: 모수를 포함할 확률이  $d\%$ 인 구간
  - 구간의 크기는 작을수록 유용함
- $d$ : 신뢰도
  - $1-d$ : 유의수준
  - 높을 수록 좋음
  - Trade-off: 신뢰도가 높아지면 구간이 커짐
- 분야마다 통용되는 신뢰도는 다름
  - 대체로 사회과학은 95% 정도
  - 일부 자연과학분야에서는  $1-10e-6$  (99.999%)을 사용하기도 함

# CI 구하기

- 표본평균에 대한 신뢰구간
  - 모평균, 모분산을 아는 경우
  - 모분산을 모르는 경우
- 평균차에 대한 신뢰구간
  - 분산을 아는 경우
  - 분산은 모르지만 두 분산이 같을 경우
- 분산에 관한 신뢰구간
- 분산비에 관한 신뢰구간

# 표본평균의 CI: 모평균, 모분산을 아는 경우

$$X_1, \dots, X_n \sim iid(\mu, \sigma^2)$$

$$\bar{X} \sim (\mu, \sigma^2/n)$$

CLT


$$\frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$$

Z Transformation

# $1-\alpha$ 신뢰구간

$$P\left(\left|\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right| < Z_{\alpha/2}\right) = 1 - \alpha$$

$$= P\left(-Z_{\alpha/2} < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < Z_{\alpha/2}\right)$$



$$= P\left(\bar{X} - Z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + Z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right)$$

**1- $\alpha$  CI**

$\mu$  가 CI 안에 있을 확률:  $1-\alpha$

# 모분산을 모르는 경우

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$$

- 모분산  $\sigma^2$  대신 표본분산  $s^2$  를 사용
- 이때 표본평균의 분포는 자유도  $n-1$ 의 t분포를 따름

$$\frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t(n - 1)$$

# 평균차 신뢰구간: 모분산이 모두 알려져 있는 경우

서로 독립

$$X_1, \dots, X_n \sim iid(\mu_1, \sigma_1^2) \quad Y_1, \dots, Y_m \sim iid(\mu_2, \sigma_2^2)$$

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim N(0,1)$$

$$(\mu_1 - \mu_2) \text{ 의 } 1-\alpha \text{ CI} \quad \bar{X} - \bar{Y} \pm Z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}$$

# 평균차 신뢰구간: 분산은 모르지만 동분산일 경우

$$\sigma_1^2 = \sigma_2^2 = \sigma^2$$

서로 독립

$$X_1, \dots, X_n \sim iid(\mu_1, \sigma^2) \quad Y_1, \dots, Y_m \sim iid(\mu_2, \sigma^2)$$

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma^2}{n} + \frac{\sigma^2}{m}}} \sim N(0,1)$$

$$s_x^2 := \sum_i^n (X_i - \bar{X})^2 / (n - 1) \quad s_y^2 := \sum_i^m (Y_i - \bar{Y})^2 / (m - 1)$$

$$\frac{(n-1)}{\sigma^2} s_x^2 \sim \chi^2(n-1)$$

$$\frac{(m-1)}{\sigma^2} s_y^2 \sim \chi^2(m-1)$$



# 동분산 평균차 신뢰구간

$$\frac{(n-1)}{\sigma^2} s_x^2 \sim \chi^2(n-1)$$

$$\frac{(m-1)}{\sigma^2} s_y^2 \sim \chi^2(m-1)$$

$$\frac{(n-1)}{\sigma^2} s_x^2 + \frac{(m-1)}{\sigma^2} s_y^2 \sim \chi^2(n-1+m-1)$$

$$\text{C2} \quad X + Y \sim \chi^2(n_1 + n_2)$$

$$s_p^2 := \frac{(n-1)s_x^2 + (m-1)s_y^2}{n+m-2}$$

Pooled Variance (합동 표본분산)

# 동분산 평균차 신뢰구간

$$C3 \quad \frac{Z}{\sqrt{X/n_1}} \sim t(n_1)$$

$$\frac{\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma^2}{n} + \frac{\sigma^2}{m}}}}{\sqrt{\frac{s_p^2}{\sigma^2}}} = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t(n + m - 2)$$

$\mu_1 - \mu_2$ 의  $1-\alpha$  CI

$$\bar{X} - \bar{Y} \pm t_{\alpha/2}(n + m - 2) s_p \sqrt{\frac{1}{n} + \frac{1}{m}}$$

# 분산 신뢰구간

$\sigma^2$ 의  $1-\alpha$  CI

$$\frac{(n-1)}{\sigma^2} s_x^2 \sim \chi^2(n-1)$$

$$\begin{aligned} 1 - \alpha &= P \left( \chi_{\alpha/2}(n-1) < \frac{(n-1)}{\sigma^2} s_x^2 < \chi_{1-\alpha/2}(n-1) \right) \\ &= P \left( \frac{(n-1)s_x^2}{\chi_{1-\alpha/2}(n-1)} < \sigma^2 < \frac{(n-1)s_x^2}{\chi_{\alpha/2}(n-1)} \right) \end{aligned}$$

# 분산비 신뢰구간

$\sigma_2^2/\sigma_1^2$  의  $1-\alpha$  CI

$$\text{C4} \quad \frac{X/n_1}{Y/n_2} \sim F(n_1, n_2)$$

$$\frac{s_x^2/\sigma_1^2}{s_y^2/\sigma_2^2} \sim F(n-1, m-1)$$

$$\begin{aligned} 1 - \alpha &= P \left( F_{\alpha/2}(n-1, m-1) < \frac{s_x^2/\sigma_1^2}{s_y^2/\sigma_2^2} < F_{1-\alpha/2}(n-1, m-1) \right) \\ &= P \left( F_{\alpha/2}(n-1, m-1) \frac{s_y^2}{s_x^2} < \frac{\sigma_2^2}{\sigma_1^2} < F_{1-\alpha/2}(n-1, m-1) \frac{s_y^2}{s_x^2} \right) \end{aligned}$$

# Next Topics

- 검정 test

# 수고하셨습니다!



# 수고하셨습니다!

